GLIP 复现及 CLIP 重排

零样本设置

本次实验采用

GLIP 预训练模型 ： glip_tiny_model_o365_goldg_cc_sbu

数据集 ： Coco.v1i.coco-segmentation_2

零样本为整个数据集，模型未进行任何额外训练

GLIP 在各类别与多类别输入下指标

数据集各类别下 mAP 结果

注：模版句为"a photo of a {class}"

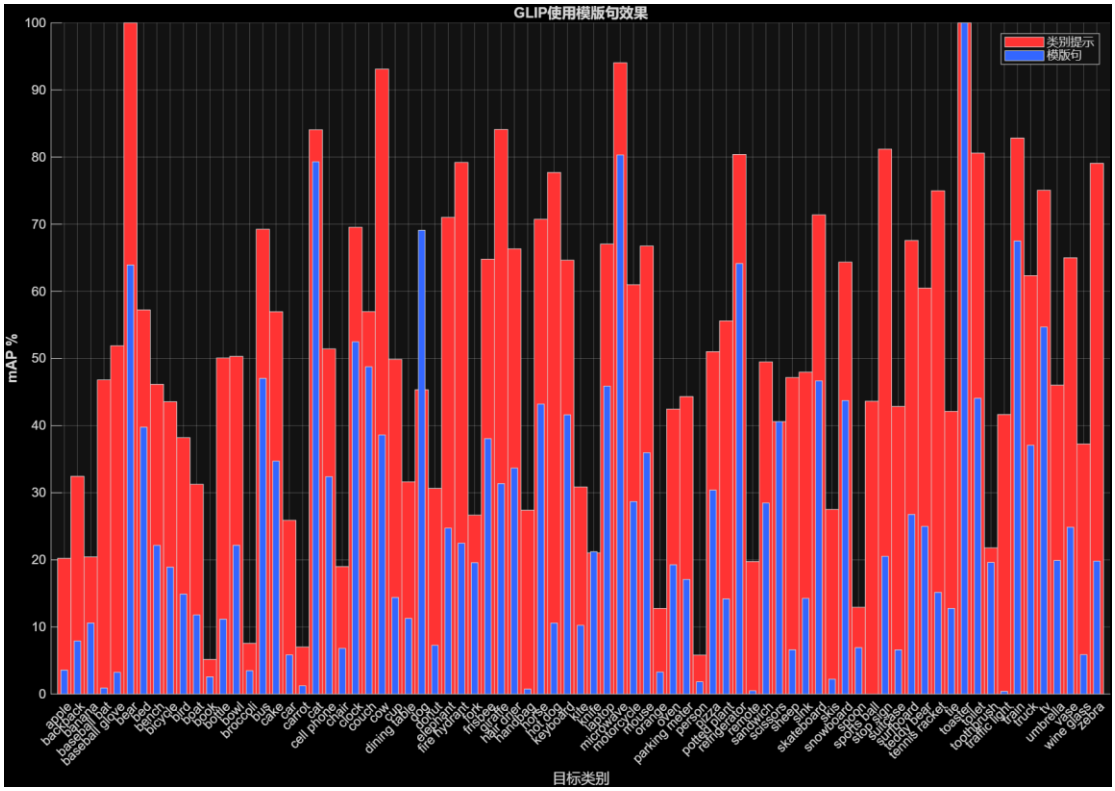

多类别输入下 GLIP 指标(num_images : 500 ; confidence_threshold: 0.3)

mAP	40.48%
AP_50	54.79%
AP_75	43.39%
AP_small	22.50%
AP_medium	43.00%
AP_large	54.81%
AR_1	35.14%
AR_10	53.22%
AR_100	55.06%
AR_small	32.84%
AR_medium	57.12%
AR_large	67.47%

探究 GLIP 中 mAP 随 confidence_threshold 变化

对数据集中 bird 类

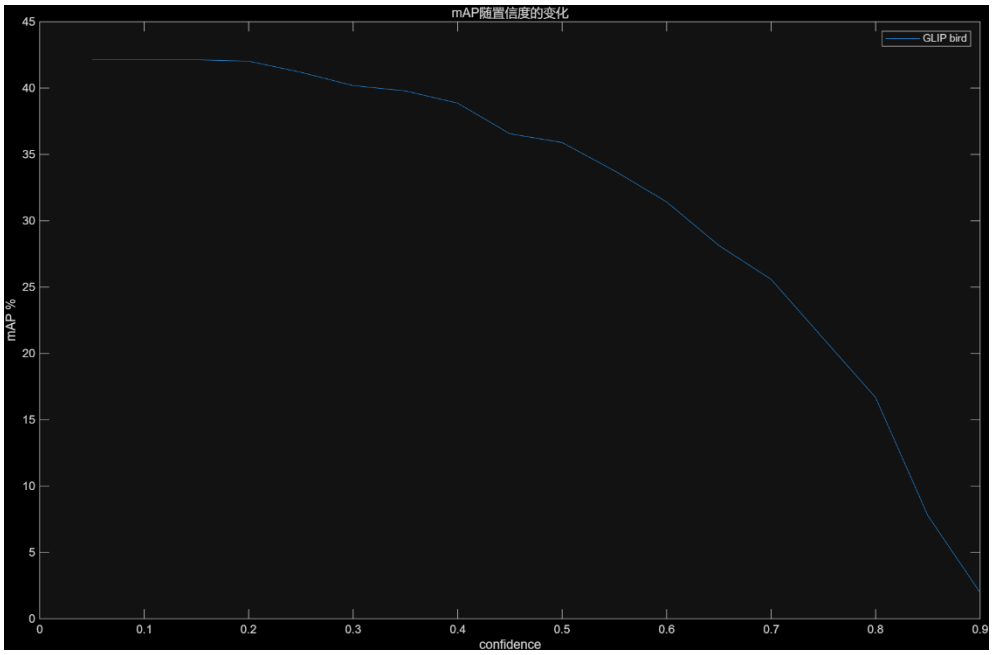

对数据集中 bear 类

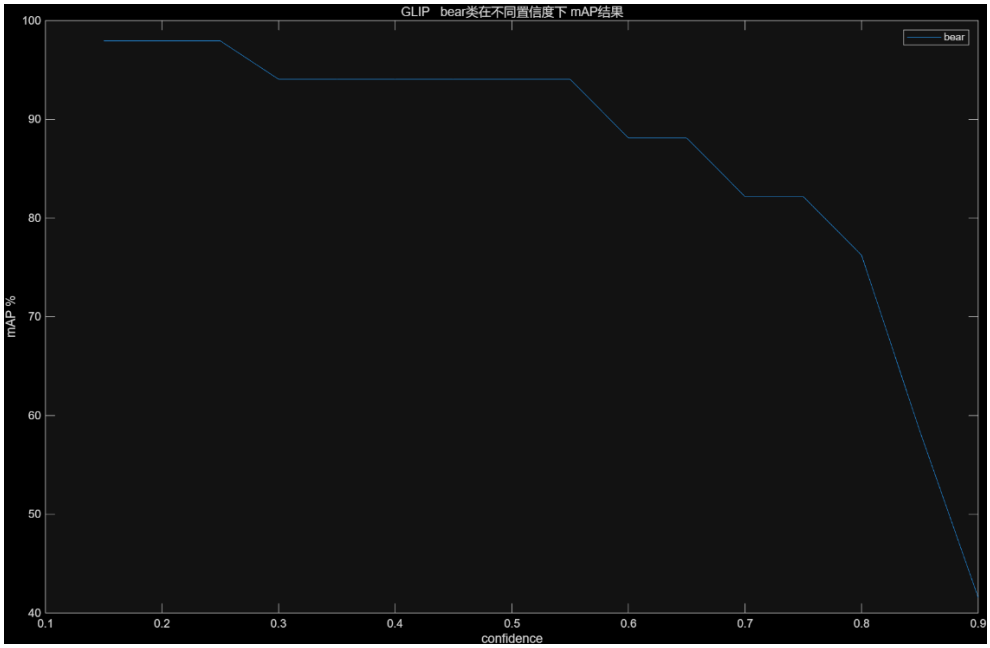

各提示词效果

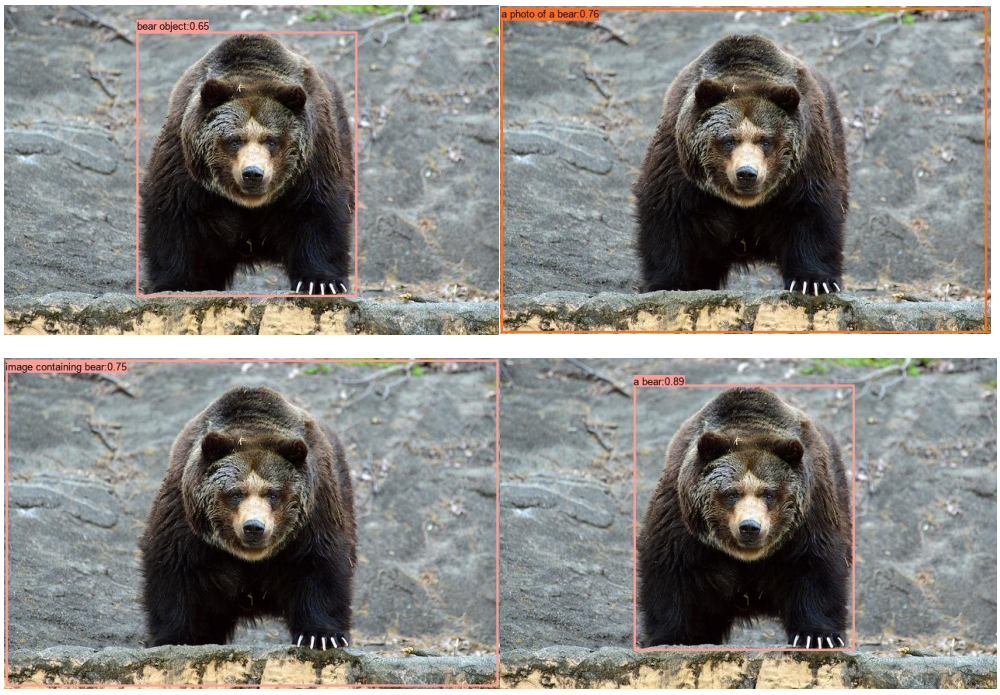

NMS 去重效果

方法说明：本方法对 GLIP 模型输出的初始检测结果进行精细化后处理。通过调用 PyTorch 框架中的 nms 函数，基于检测框的 IoU（交并比）阈值对高度重叠的候选框进行筛选去重，仅保留置信度最高的检测框。这一步骤能够有效减少冗余检测，提升最终预测结果的准确性和可读性。

核心流程：

1. 收集 GLIP 模型在各个图片上检测到的目标框及其置信度分数
2. 调用 torchvision.ops.nms 函数，根据预设的 IoU 阈值（self.iou_threshold）对同一类别内的检测框进行非极大值抑制
3. 结合置信度阈值（conf_threshold）过滤低质量检测框
4. 返回经过筛选的精简预测结果，用于后续的 mAP 评估

效果：

未进行 NMS 去重

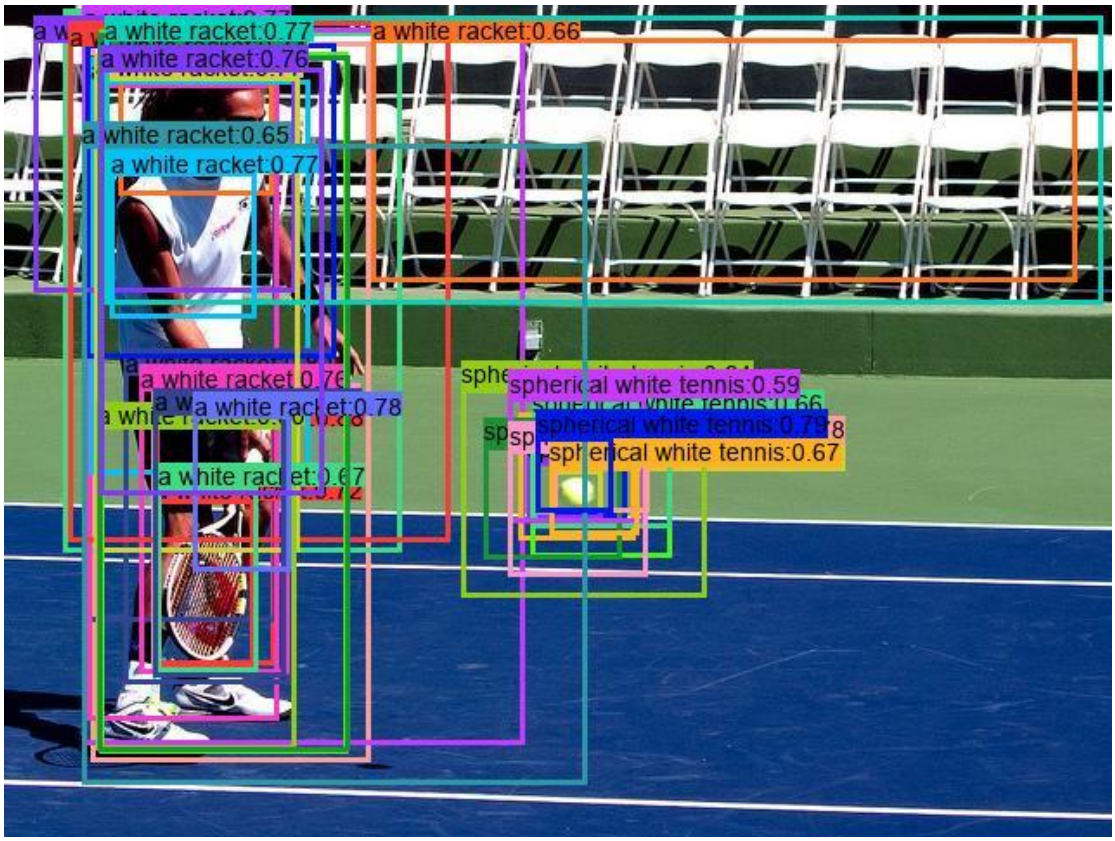

进行 NMS 去重

CLIP 打分重排

改进动机：针对 GLIP 模型在实际场景中存在的类别误识别问题，提出基于 CLIP 的类别重打分机制。GLIP 虽然能准确定位目标，但在复杂场景下类别预测准确率有限；CLIP 基于大规模图文预训练，具备更强的语义理解和泛化能力。本方法融合两者优势：保留 GLIP 的定位能力，同时利用 CLIP 对每个候选框进行类别重判，最终通过加权融合（alpha 参数）得到更准确的分类结果。

推理流程：

1. GLIP 检测：输入图像，生成候选框及初始置信度

2. 图像裁剪：根据检测框裁剪目标区域

3. CLIP 分类：对裁剪区域进行图文匹配，计算各类别概率

4. 分数融合：加权融合 GLIP 分数和 CLIP 分数（alpha 参数）

效果:

未进行 CLIP 重排结果

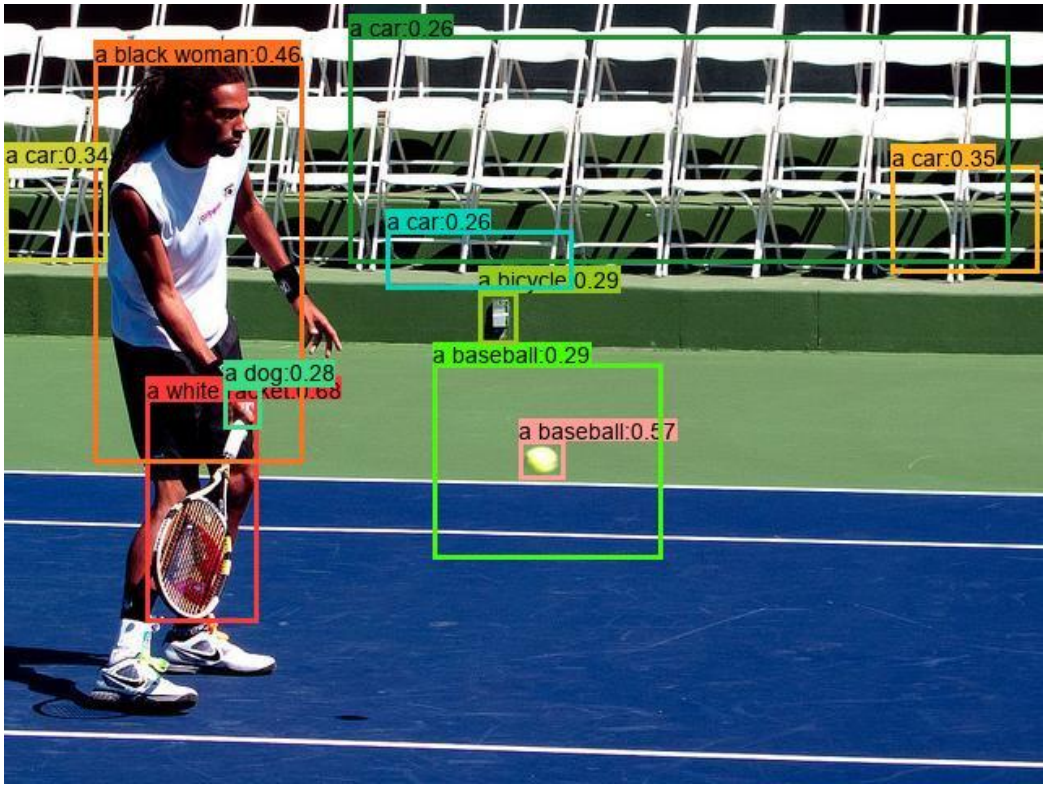

进行 CLIP 重排结果

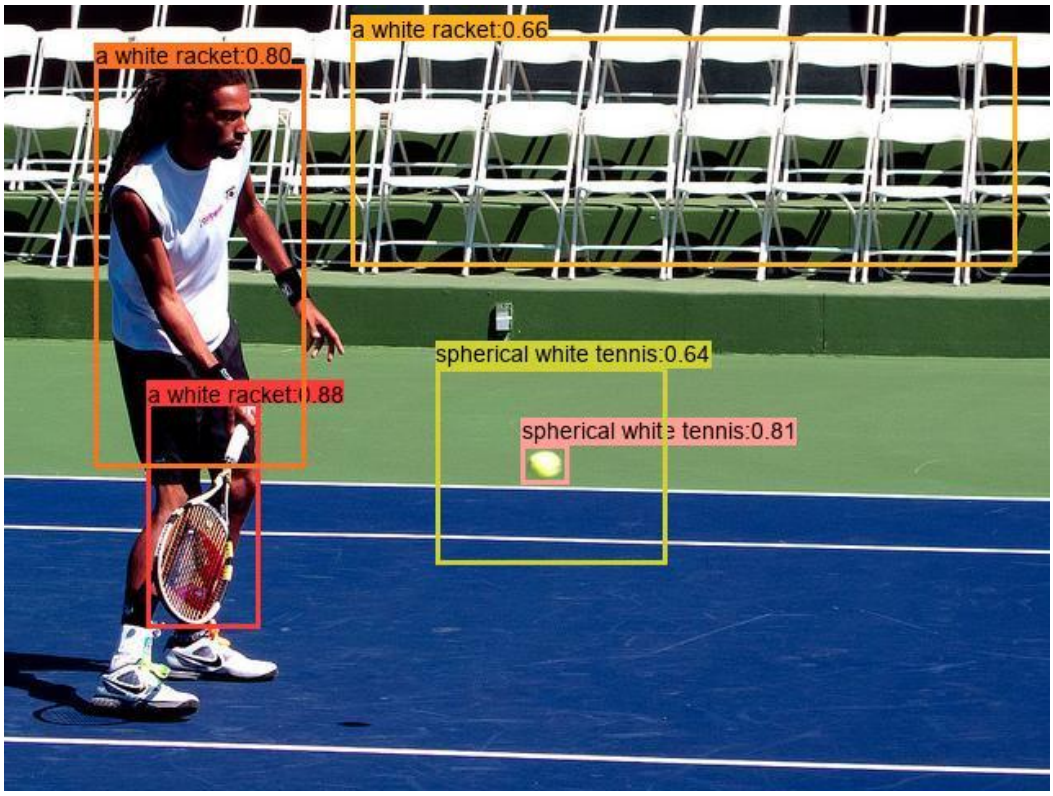

其余优化

1. pytorch2.0 编译

```
torch.compile(model=glip_demo.model,
              mode="max-autotune",
              backend="cudagraphs")
```

2. 推理使用半精度推理优化

```
3. with torch.amp.autocast(device_type='cuda', dtype=torch.float16):
```

注： 非全半精度，为混合精度推理